

CIENCIA DE DATOS

Proyecto Final: Explicabilidad en Modelos de Caja Negra (XAI) y Redacción

1. Introducción y Contexto

En la práctica de la ciencia de datos, lograr una alta precisión predictiva ya no es el único objetivo. En sectores regulados o de alto impacto (medicina, finanzas, legal), es imperativo entender *por qué* un modelo toma una decisión.

Este proyecto final busca que apliques las técnicas de Inteligencia Artificial Explicable (AI) revisadas en el curso (LIME y SHAP) sobre un modelo de aprendizaje automático complejo ("caja negra") utilizando un conjunto de datos público. Deberás documentar tus hallazgos bajo la estructura estricta de un artículo de investigación científica de nivel Q1 (formato IEEE) y defender tu trabajo en una interrogación oral.

2. Objetivos del Proyecto

- Desarrollar un modelo predictivo robusto utilizando algoritmos complejos (ej. *XGBoost*, *Random Forest*, *LightGBM*, *Neural Networks*).
- Implementar, contrastar y evaluar las metodologías de explicabilidad **SHAP** (enfoque global y local basado en teoría de juegos) y **LIME** (enfoque local basado en modelos subrogados).
- Comunicar los resultados con rigor científico adoptando los estándares de una publicación de primer cuartil (Q1) y defender el trabajo bajo cuestionamiento técnico.

3. Estructura de las Últimas Evaluaciones (Hitos)

El proyecto comprende las últimas dos evaluaciones del curso. La fecha límite de entrega para todos los componentes escritos y de código es el lunes 29 de junio.

Evaluación 3: Algoritmo y Documentación en Artículo (30%)

Consiste en la entrega formal del desarrollo técnico y el manuscrito científico en un repositorio estructurado (GitHub/GitLab).

1. **El Algoritmo (Código):** Un Jupyter Notebook limpio, documentado y reproducible que incluya el pipeline de datos, entrenamiento del modelo de caja negra y la correcta implementación de las librerías shap y lime.
2. **La Documentación (Artículo):** Un manuscrito en formato PDF generado obligatoriamente a partir de la plantilla oficial de la IEEE (en Overleaf/LaTeX o Word) que emule la estructura de una publicación Q1:
 - **Abstract & Keywords:** Resumen conciso del problema, metodología y hallazgos clave de explicabilidad.

- **I. Introduction:** Contexto, motivación de usar XAI en ese dominio y objetivos.
- **II. Related Work:** Breve revisión del estado del arte (mínimo 5 referencias bibliográficas indexadas).
- **III. Methodology:** Descripción del dataset, arquitectura del modelo de caja negra y fundamento matemático/lógico de **SHAP** (Valores de Shapley) y **LIME** (Perturbación local y pesos).
- **IV. Experimental Results:** Gráficos de rendimiento del modelo y visualizaciones analizadas de SHAP (global/local) y LIME (local).
- **V. Discussion:** Interpretación del sentido práctico/social/económico de las variables según el modelo y *contraste entre las explicaciones locales que entregan SHAP y LIME para un mismo individuo*.
- **VI. Conclusions & Future Work:** Resumen de aportes y siguientes pasos.

Evaluación 4: Presentación e Interrogación Individual (40%)

Una vez entregado el material el 30 de junio, se agendarán las sesiones de defensa grupal, las cuales consisten en:

1. **Presentación (Grupal):** Una exposición ejecutiva y fluida de máximo 15 minutos apoyada en diapositivas donde se sintetice el problema, el modelo predictivo y los descubrimientos más potentes de XAI.
2. **Interrogación y Preguntas Individuales:** Una ronda de preguntas dirigida por el equipo docente. **Cada integrante del grupo será evaluado de forma individual** sobre su comprensión teórica de los modelos utilizados, la matemática/lógica detrás de SHAP y LIME (ej. *¿cómo define LIME su entorno de vecindad?* o *¿por qué SHAP cumple con la propiedad de aditividad?*), y su capacidad para defender críticamente las decisiones del proyecto.

4. Sugerencias de Datasets Públicos

Se requiere el uso de conjuntos de datos públicos con un impacto social o de negocio claro. Se sugieren las siguientes opciones (disponibles en Kaggle o el repositorio UCI):

Dataset	Dominio	Tipo de Problema	¿Por qué es interesante para XAI?
Heart Disease Cleveland (UCI)	Salud / Medicina	Clasificación Binaria	Identificar qué factores clínicos (colesterol, presión) disparan el riesgo cardíaco según el modelo.
German Credit Risk (Kaggle/UCI)	Finanzas / Banca	Clasificación	Crucial para entender la equidad (<i>fairness</i>) y evitar sesgos en la aprobación de créditos a personas.
California Housing Prices (StatLib)	Inmobiliario	Regresión	Analizar cómo interactúan variables geográficas y socioeconómicas en el precio de la vivienda de forma global y local.
Predict Student Dropout (UCI)	Educación	Clasificación Multiclase	Explicar qué factores (socioeconómicos vs. académicos) determinan la deserción universitaria para tomar medidas preventivas.

5. Ejemplo Práctico de Referencia (Sección Resultados del Artículo)

A modo de guía, un flujo de trabajo esperado para la argumentación del artículo e interrogación sería:

Ejemplo de aplicación en el dataset *German Credit Risk*:

- **Modelo:** Se entrena un *Gradient Boosting Classifier* para predecir si un cliente caerá en impago (Default). El modelo alcanza un AUC-ROC = 0.85.
- **Análisis Global (SHAP Summary Plot):** Permite identificar en el artículo que las variables Duration of Credit (Duración del crédito) y Account Status (Estado de la cuenta) son las más determinantes a nivel macro para el modelo.
- **Análisis Local Comparativo (SHAP vs LIME):** Se toma el caso específico del *Cliente #142*, a quien el modelo le denegó el crédito con un 89% de probabilidad.
 - En el artículo, deben mostrar el gráfico de cascada (*Waterfall plot*) de **SHAP** y el gráfico de barras de **LIME** para ese cliente, analizando si ambos algoritmos coinciden en que la "duración del crédito" fue la causa principal del rechazo.
- **En la Interrogación Individual:** Se le podría preguntar a un estudiante: *Para el Cliente #142, LIME y SHAP dieron pesos ligeramente distintos a las variables. Explique teóricamente a qué se debe esto considerando cómo construye cada algoritmo su explicación local.*

6. Criterios de Evaluación y Rúbrica General

- **Rigor Técnico y Código (Ev3 - 30% compartido con artículo):** Correcto tratamiento de datos, entrenamiento adecuado del modelo y uso óptimo de las librerías shap y lime.
- **Calidad de la Redacción Científica (Ev3 - 30% compartido con código):** Claridad, tono formal y cumplimiento estricto del formato IEEE (márgenes, tipografía, formato de ecuaciones y referencias).
- **Calidad de la Exposición (Ev4 - 40% compartido con interrogación):** Dominio del tiempo, claridad al explicar gráficos complejos de SHAP/LIME y fluidez del grupo.
- **Dominio Teórico Individual (Ev4 - 40% compartido con exposición):** Capacidad del alumno para responder individualmente preguntas profundas sobre la matemática y lógica detrás de SHAP (teoría de juegos) y LIME (modelos lineales locales), demostrando comprensión absoluta y autoría del trabajo entregado.